
Порождающие модели для прогнозирования (наборов временных рядов) в метрическом вероятностном пространстве

A Preprint

Карпеев Глеб
Кафедра интеллектуальных систем
МФТИ
karpeev.ga@phystech.edu

Vadim Strijov
FRC CSC of the RAS
Moscow, Russia
strijov@phystech.edu

Яковлев Константин
Кафедра интеллектуальных систем
МФТИ
iakovlev.kd@phystech.edu

Abstract

Исследование посвящено проблеме прогнозирования временных рядов с высокой ковариацией. Задача решается для наборов временных рядов с высокой дисперсией, проявляющейся, например, в сигналах головного мозга или ценах финансовых активов. Для решения данной задачи предлагается построение пространства парных расстояний, представляющего метрическую конфигурацию временных рядов. Прогноз осуществляется в данном пространстве, а затем результат возвращается в исходное пространство с использованием метода многомерного шкалирования. В данной работе изучаются порождающие модели для прогнозирования наборов временных рядов в метрическом вероятностном пространстве. Новизна работы заключается в применении Римановых моделей для регрессии и использовании Римановых генеративных диффузных моделей.

Keywords Riemannian Generative Models · Trades

1 Introduction

Развитие технологий, которое мы наблюдаем в последние годы, открывает перед нами широкие возможности для получения данных, передаваемых человеком с помощью различных устройств. Анализ данных систем, предназначенных для мониторинга состояния человека, позволяет решать задачи в сфере здравоохранения, которые включают в себя анализ сигналов головного мозга [1], мониторинга физической активности [2]. Задача прогнозирования временного ряда является важной частью анализа сигналов и может использоваться во многих биомедицинских приложениях.

В данной работе предлагается метод прогнозирования временных рядов с высокой ковариацией и высокой дисперсией. Предлагаемое решение задачи прогнозирования состоит из трех этапов. Во-первых, осуществляется построение пространства парных расстояний, где используемая метрика удовлетворяет условию Мерсера. Во-вторых, выполняется прогноз матрицы попарных расстояний. В-третьих, результат возвращается в исходное пространство. В данной работе изучаются Римановы генеративные диффузные модели (RSGMs) [3] для выполнения прогнозирования матрицы попарных расстояний.

Классическими алгоритмами прогнозирования временных рядов являются метод SSA (Singular Spectrum Analysis) [4], LSTM [5], State space model [6]. Новизна предложенного метода заключается в том, что выполняется кодирование временных рядов с помощью матрицы расстояний, выполняется прогноз, а затем декодирование полученной матрицы.

Анализ предлагаемого метода прогнозирования проводится на синтетических и реальных данных. Синтетический набор данных построен на основе синусоидальных сигналах со случайной амплитудой и частотой. Реальные данные были получены с помощью акселерометра, а так же на основе финансовых временных рядов. Целью эксперимента является нахождение оптимальной модели для прогнозирования временных рядов.

2 Problem Statement

Даны временные ряды с высокой ковариацией и высокой дисперсией

$$x_1, x_2, \dots, x_T \in \mathbb{R}^d, \quad (1)$$

где d — количество временных рядов.

Нужно спрогнозировать x_{T+1} .

Алгоритм:

1. Построить матрицу расстояний.

$$\hat{\Sigma}_T = \frac{1}{T} \sum_{t=1}^T (x_t - \mu_T)(x_t - \mu_T)^T \quad (2)$$

$$\mu_T = \frac{1}{T} \sum_{t=1}^T x_t \quad (3)$$

2. Спрогнозировать матрицу $\hat{\Sigma}_{T+1}^s \approx \hat{\Sigma}_{T+1} | \hat{\Sigma}_T$

Базовый алгоритм - линейная регрессия:

$$\hat{\Sigma}_{T+1}^s = W \cdot \hat{\Sigma}_T \quad (4)$$

3. Найти такой оптимальный x_{T+1} , что ошибка прогнозирования временных рядов

$$\|\hat{\Sigma}_{T+1}^s - \hat{\Sigma}_{T+1}\|_2 \rightarrow \min_{x_{T+1}} \quad (5)$$

3 Computation experiment

Эксперимент проводился на реальных и синтетических данных. Синтетический набор данных построен на основе синусоидальных сигналах со случайной амплитудой и частотой. Реальные данные были получены с энергетической биржи Nord Pool [8] и представляют собой временной ряд цены на электроэнергию. Временной ряд энергии состоит из почасовых записей (всего 50826 наблюдений).

Для оценивания качества аппроксимации вычисляется значение среднеквадратичной ошибки.

$$MSE(y_{pred}, y_{true}) = \frac{1}{n} \sum_{i=1}^n (y_{pred} - y_{true})^2 \quad (6)$$

Сравним два базовых алгоритма предсказания временных рядов - SSA и MSSA.

3.1 Синтетические данные

Сгенерируем выборку из двух синусоидальных сигналов размера $N = 200$, с количеством периодов 2 и 4, соответственно. Предскажем последние 40 значений выборки, для предсказания будем использовать последние 60 сгенерированных значений.




Рис. 1: Прогноз синуса с 4 периодами алгоритмом SSA




Рис. 2: Прогноз синуса с 2 и 4 периодами алгоритмом MSSA




Рис. 3: Прогноз синуса с 4 периодами алгоритмом LSTM




Рис. 4: Прогноз сильно зашумленного синуса с 4 периодами алгоритмом LSTM




Рис. 5: Прогноз сильно зашумленного синуса с 2 и 4 периодами алгоритмом MSSA

3.2 Данные цен на электроэнергию

Строка матрицы X — локальная история сигнала за одну неделю $n = 24 \times 7$. Строка матрицы Y — локальный прогноз потребления электроэнергии в следующие 24 часа. Прогноз выполняется с помощью алгоритма SSA.




Рис. 6: Корреляция между временными рядами




Рис. 7: Прогноз спотовых цен на электроэнергию алгоритмом SSA

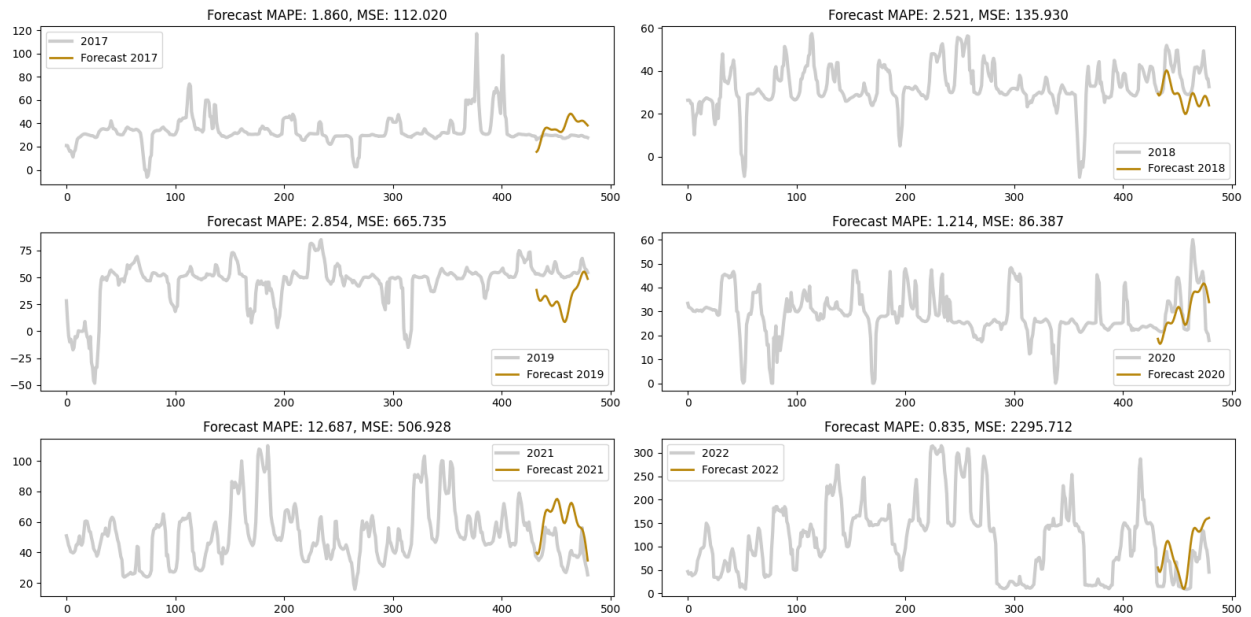


Рис. 8: Прогноз спотовых цен по годам на электроэнергию алгоритмом MSA




Рис. 9: Pareto front для MSSA прогноза

4 LSTM-Attention

Модель LSTM-attention-LSTM использует две модели LSTM в качестве кодера и декодера и вводит механизм внимания между кодером и декодером. Модель имеет две отличительные особенности: во-первых, используя механизм внимания для расчета взаимосвязи между данными последовательности, она преодолевает недостаток модели кодера-декодера, заключающийся в том, что декодер не может получить достаточно длинные входные последовательности; во-вторых, он подходит для последовательного прогнозирования с большими временными шагами.

Список литературы

- [1] S. Vaid, P. Singh and C. Kaur, "EEG Signal Analysis for BCI Interface: A Review, 2015 Fifth International Conference on Advanced Computing & Communication Technologies, Haryana, India, 2015
- [2] Amit Purwar, Do Un Jeong and Wan Young Chung, "Activity monitoring from real-time triaxial accelerometer data using sensor network,"2007 International Conference on Control, Automation and Systems, Seoul, Korea (South), 2007
- [3] Riemannian Score-Based Generative Modelling. Valentin De Bortoli, Émile Mathieu, Michael Hutchinson, James Thornton, Yee Whye Teh, Arnaud Doucet, 2022
- [4] Elsner, J.B. and Tsonis, A.A. (1996): Singular Spectrum Analysis. A New Tool in Time Series Analysis, Plenum Press.
- [5] Hochreiter, Sepp & Schmidhuber, Jürgen. (1997). Long Short-term Memory. Neural computation.
- [6] Koller D, Friedman N. (2009) Probabilistic Graphical Models. Cambridge, MA: MIT Press.
- [7] Dataset for "Trades Quotes and Prices"
- [8] Electricity Spot Price Data. <https://www.kaggle.com/datasets/arashnic/electricity-spot-price>